

Juliano Almeida Machado

Análise comparativa de modelos de Predição do Nível da Água no Rio Guaíba

Porto Alegre, Brasil

2025

Juliano Almeida Machado

Análise comparativa de modelos de Predição do Nível da Água no Rio Guaíba

Trabalho de Conclusão apresentado à Comissão de Graduação dos Cursos de Física da Universidade Federal do Rio Grande do Sul, como requisito parcial para obtenção do título de Bacharel em Física.

Universidade Federal do Rio Grande do Sul – UFRGS

Instituto de Física

Orientador: Sebastián Gonçalves

Porto Alegre, Brasil

2025

Juliano Almeida Machado

Análise comparativa de modelos de Predição do Nível da Água no Rio Guaíba/ Juliano Almeida Machado. – Porto Alegre, Brasil, 2025-
45p. : il. (algumas color.) ; 30 cm.

Orientador: Sebastián Gonçalves

Trabalho (Conclusão de Curso) – Universidade Federal do Rio Grande do Sul – UFRGS
Instituto de Física, 2025.

1. Séries Temporais. 2. Enchentes. 3. Guaíba. I. Orientador. II. Universidade Federal do Rio Grande do Sul. III. Instituto de Física. IV. Título

Juliano Almeida Machado

Análise comparativa de modelos de Predição do Nível da Água no Rio Guaíba

Trabalho de Conclusão apresentado à Comissão de Graduação dos Cursos de Física da Universidade Federal do Rio Grande do Sul, como requisito parcial para obtenção do título de Bacharel em Física.

Trabalho aprovado. Porto Alegre, Brasil, 17 de dezembro de 2024:

Sebastián Gonçalves
Orientador

Professor
Convidado 1

Professor
Convidado 2

Porto Alegre, Brasil
2025

Agradecimentos

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Resumo

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Palavras-chave: latex. abntex. editoração de texto.

Abstract

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Keywords: latex. abntex. text editoration.

Lista de abreviaturas e siglas

ABNT	Associação Brasileira de Normas Técnicas
abnTeX	ABsurdas Normas para TeX
XGBoost	eXtreme Gradient Boosting
LSTM	Long Short Term Memory
ARIMA	Autoregressive integrated moving average
SARIMA	Seasonal autoregressive integrated moving average
RNN	Rede Neural Recorrente
CNN	Rede Neural Convolucional
RMPOA	Região Metropolitana de Porto Alegre
MLP	Multilayer Perceptron
NHITS	Neural Hierarchical Interpolation for Time Series Forecasting
SNIRH	Sistema Nacional de Informações sobre Recursos Hídricos

Sumário

1	INTRODUÇÃO	15
I	REFERENCIAIS TEÓRICOS	19
2	REVISÃO BIBLIOGRÁFICA	21
3	REVISÃO DOS MODELOS UTILIZADOS	23
3.1	Long Short Term Memory	23
3.2	Neural Hierarchical Interpolation for Time Series Forecasting	23
3.3	Neural Basis Expansion Analysis for Interpretable Time Series Forecasting	23
3.4	Neural Basis Expansion Analysis for Interpretable Time Series Forecasting	23
II	PREPARAÇÃO DA PESQUISA	25
4	FONTE DE DADOS	27
5	PRÉ-PROCESSAMENTO DE DADOS	29
6	PLANEJAMENTO DA PESQUISA	31
7	FERRAMENTAS E RECURSOS UTILIZADOS	33
III	RESULTADOS	35
8	CONCLUSÃO	37
	REFERÊNCIAS	39
	APÊNDICE A – QUISQUE LIBERO JUSTO	43
	ANEXO A – MORBI ULTRICES RUTRUM LOREM.	45

1 Introdução

Desastres naturais provocados por eventos climáticos extremos causam impactos profundos e severos de diversas maneiras. No aspecto econômico, os recursos alocados para a recuperação de áreas afetadas enfraquecem a microeconomia local, tornando a região ainda mais vulnerável a eventos futuros. Estruturalmente, o tempo e o dinheiro investidos na construção e no aprimoramento de edificações, tanto privadas (como residências e negócios) quanto públicas (como infraestrutura urbana e áreas administrativas), podem ser comprometidos pela falta de preparação para lidar com tais ocorrências. Já o impacto social é, sem dúvida, o mais significativo. Este impacto, imensurável, é sentido por diversas gerações de pessoas afetadas por desastres, como evidenciado pelos efeitos do furacão Katrina [27] [25].

Devido às mudanças climáticas, a frequência e intensidade dos desastres naturais vêm aumentando globalmente desde os anos 1950, como evidenciado por Dunn et al. (2024) [14]. Como resultado, muitas regiões vem sendo afetadas por eventos climáticos extremos de maneira acelerada, causando um significativo despreparo. Entre esses desastres, as enchentes se destacam pela sua capacidade de causar destruição generalizada e afetar áreas densamente povoadas, especialmente em regiões urbanas com infraestrutura inadequada para gerenciar grandes volumes de água. Em muitos casos, essa inadequação é agravada pela falta de manutenção de sistemas essenciais, como drenagem urbana, diques ou canais fluviais, tornando as cidades vulneráveis mesmo quando dispõem de estruturas projetadas para lidar com grandes fluxos de água.

No final de abril e início de maio de 2024, o estado do Rio Grande do Sul passou por um período de alta precipitação que resultou na cheia das suas principais bacias hidrográficas. Na região metropolitana de Porto Alegre (RMPOA), esse cenário culminou na maior cheia histórica do Rio Guaíba, que ultrapassou o recorde histórico de 4.76 metros estabelecido pela a cheia de 1941, até então considerada a mais devastadora da cidade [10]. Em Porto Alegre o Rio Guaíba atingiu em 5 de maio o nível de 5.33 metros devido à falhas no sistema de contenção de cheias, composto por muros, diques, comportas e estações de bombeamento [9]. Bairros inteiros como Centro Histórico, Menino Deus e Sarandi foram alagados, forçando evacuações das áreas mais afetadas e tornando ruas transitáveis apenas de barco. As principais vias de acesso à capital foram interditadas, interrompendo abastecimentos e causando escassez de água e energia elétrica para milhares de moradores. Esse desastre foi impulsionado por uma combinação de fatores meteorológicos, e, combinado com a maior vulnerabilidade de centros urbanos à enchentes [28] [16] [21] [26], levou à um evento de devastação generalizada, com milhares de pessoas deslocadas e centenas de vítimas fatais [2].

Durante a gestão da crise, o monitoramento e predição dos níveis de água do Rio Guaíba – o mais importante da região – foi fundamental para orientar os tomadores de decisão em suas ações de planejamento e para que à população pudesse reagir melhor à ameaça iminente. Essas previsões foram feitas principalmente através de modelos hidrológicos e hidrodinâmicos, que, embora precisos, são complexos, exigem grande quantidade de dados topográficos, meteorológicos e hidrológicos, requerem conhecimento especializado em hidrologia e demandam tempo de simulação prolongado. Esse último fator foi acentuado nos momentos mais delicados da crise, quando as previsões só podiam ser realizadas com uma frequência diária [18], o que as tornou insuficientes para atender às demandas de previsões em curto prazo ou em tempo real [3].

Uma alternativa que visa superar essas limitações são os modelos baseados em dados, que utilizam técnicas para identificar e explorar relações estatísticas entre os dados de entrada e saída. Com a aprendizagem dos padrões presentes nos dados históricos, é possível mapear as dinâmicas subjacentes do sistema e utilizá-las para prever valores futuros. Assim, esses modelos são capazes de realizar previsões precisas com base em séries temporais, capturando tendências e comportamentos complexos que podem ser difíceis de modelar diretamente por meio de abordagens tradicionais. Diferentemente das mesmas, que demandam tempo e dados específicos, os modelos baseados em dados oferecem maior agilidade para previsões em tempo real, sendo uma escolha mais adequada para sistemas de alerta precoce e mitigação de desastres de cheias [8].

Uma das maiores vantagens de utilizar essa abordagem é o grande desenvolvimento do campo de Análise e Predição de Séries Temporais. Com isso, é possível utilizar as técnicas desenvolvidas para a aplicação em problemas com uma modelagem semelhante, mas em contextos distintos [17], como Economia, Biologia, entre outros. Dentro deste contexto, uma ampla gama de modelagens são utilizadas para a predição de séries temporais. Isso apresenta uma oportunidade de análise e comparação entre as vantagens e desvantagens das mesmas com o intuito de descobrir a mais efetiva para a situação particular [22] [23].

Uma abordagem mais clássica e altamente implementada destes modelos vem na forma de modelos estatísticos, como o ARIMA (*Autoregressive Integrated Moving Average*) [5], um modelo que descreve processos estocásticos usando uma combinação de autoregressão, isto é, a predição de uma Série Temporal usando somente valores anteriores da mesma, a média móvel - ajuste das previsões considerando os erros residuais das observações anteriores, o que permite capturar flutuações - e, por último, a diferenciação dos valores consecutivos da série, reduzindo o impacto de padrões de longo prazo e tendências. Além disso, um elemento de sazonalidade, ou seja, padrões repetidos em com uma certa frequência fixa, como padrões mensais ou trimestrais, podem ser compreendidos através de uma extensão do ARIMA, o SARIMA. Historicamente, esses modelos têm sido usados em predições em contextos semelhantes como em Atashi et al. (2022) [3]

que comparou o desempenho do SARIMA com os modelos LSTM e *Random Forest* para predição do nível da água no Rio Vermelho do Norte, localizado na fronteira entre os Estados Unidos e o Canadá, e Gldal et al. (2009) [15] que utilizou o ARMA para a predição do Lago Egirdir na Trquia, oferecendo uma base slida para comparaes com mtodos modernos.

Esses modelos, eficazes e de baixo custo computacional, apresentam tanto limitaes quanto vantagens quando comparados com modelos mais recentes desenvolvidos nas reas de Aprendizado de Mquina (*Machine Learning*) e Aprendizado Profundo (*Deep Learning*) [20]. No mbito de *Machine Learning*, modelos baseados em *Gradient Boosting* tm se mostrado promissores em situaes de desastres, onde a rapidez e preciso nas previses so essenciais para mitigar impactos [1]. Um exemplo amplamente utilizado  o XGBoost (*eXtreme Gradient Boosting*) [7]. O mesmo utiliza rvores de deciso em srie, ajustando constantemente os erros das previses anteriores. Alm disso, ele incorpora regularizao para reduzir o risco de sobreajuste (*overfitting*) e otimizaes especficas para lidar com grandes volumes de dados. Uma implementao semelhante, visando reduzir o tempo computacional,  dada pelo LightGBM [19]. Ela mantm as vantagens do XGBoost, como otimizao para dados esparsos, treinamento paralelo, mltiplas funes de perda e regularizao, mas altera o mtodo de construo das rvores de deciso, mostrando-se uma boa alternativa para obter resultados semelhantes de forma mais eficaz, algo imprescindvel no contexto de uma crise climtica como a ocorrida.

Por outro lado, em Aprendizado Profundo, modelos baseados em Redes Neurais Recorrentes (RNNs), como o *Long Short Term Memory* (LSTM), so amplamente utilizados em situaes semelhantes, como demonstrado por Borwarnginn et al. [4]. O LSTM foi projetado especificamente para lidar com dependncias de longo prazo em sries temporais, garantindo que informaes relevantes de eventos passados sejam preservadas, ao mesmo tempo que mantm o contexto de eventos mais recentes. Essa anlise  particularmente til em problemas onde padres temporais complexos e, geralmente, no lineares precisam ser modelados.

Alm dos modelos baseados em RNNs, outra abordagem amplamente utilizada em Aprendizado Profundo so as baseadas em Redes Neurais Perceptron Multicamadas (MLP, *Multilayer Perceptron*). Diferentemente das RNNs, que so projetadas para processar dados sequenciais, as MLPs utilizam camadas conectadas para identificar padres em conjuntos de dados estruturados. Um exemplo  o modelo NHITS (*Neural Hierarchical Interpolation for Time Series Forecasting*) [6] que adapta a arquitetura MLP para o contexto de sries temporais. O NHITS emprega uma estratgia hierrquica para interpolar e extrair caractersticas relevantes em diferentes escalas temporais, permitindo capturar tanto padres de curto quanto de longo prazo. Com isso, apresenta uma grande capacidade de lidar com sries temporais irregulares ou com alta variabilidade.

Com todas essas diferentes abordagens em mente, este estudo tem como objetivo principal aplicar essas técnicas no contexto específico de predição do nível da água durante as enchentes do Rio Guaíba. O foco está em avaliar a eficácia de cada modelo na previsão de séries temporais em um cenário crítico, onde precisão e rapidez são essenciais para a tomada de decisões. Para isso, serão utilizados diferentes métodos, abrangendo desde abordagens estatísticas, como SARIMA, até modelos mais recentes como XGBoost, LSTM, NHITS e outros. A comparação do desempenho desses modelos será realizada com base em métricas amplamente reconhecidas na literatura, como o *Root Mean Squared Error* (RMSE), que mede a magnitude média dos erros quadráticos; o *Mean Absolute Error* (MAE), que avalia os erros médios absolutos e fornece uma visão clara da precisão geral; e o *Nash-Sutcliffe Model Efficiency Coefficient* (NSE), que avalia a eficiência preditiva em relação à média observada.

Além disso, será considerada a capacidade dos modelos de lidar com variáveis externas, como precipitação, vento, nível de rios afluentes e outros fatores que influenciam diretamente o nível do Rio Guaíba. Com isso, busca-se não apenas determinar qual análise oferece o menor erro preditivo, mas também compreender como cada técnica responde a diferentes dinâmicas do sistema e sua aplicabilidade em situações de gestão de desastres. Essa análise contribuirá para o desenvolvimento de estratégias mais robustas e eficazes para a mitigação de impactos de enchentes futuras.

Para esta análise, serão utilizados dados obtidos das estações telemétricas relevantes através do Sistema Nacional de Informações sobre Recursos Hídricos (SNIRH), que disponibiliza informações das principais bacias hidrográficas do Brasil [12]. Esses dados serão a base para as séries históricas do nível das águas do Guaíba, complementados por dados externos, como os do MERRA-2 (*Modern-Era Retrospective analysis for Research and Applications, Version 2*), um projeto da NASA que integra observações de satélites e estações terrestres para gerar dados meteorológicos globais [24]. Dados meteorológicos adicionais serão obtidos a partir de fontes públicas, como o Instituto Nacional de Meteorologia (INMET) e o Instituto Brasileiro de Geografia e Estatística (IBGE) [13] [11].

Parte I

Referenciais teóricos

2 Revisão Bibliográfica

3 Revisão dos modelos utilizados

3.1 Long Short Term Memory

3.2 Neural Hierarchical Interpolation for Time Series Forecasting

3.3 Neural Basis Expansion Analysis for Interpretable Time Series Forecasting

3.4 Neural Basis Expansion Analysis for Interpretable Time Series Forecasting

Parte II

Preparação da pesquisa

4 Fonte de Dados

5 Pré-processamento de dados

6 Planejamento da pesquisa

7 Ferramentas e recursos utilizados

Parte III

Resultados

8 Conclusão

Sed consequat tellus et tortor. Ut tempor laoreet quam. Nullam id wisi a libero tristique semper. Nullam nisl massa, rutrum ut, egestas semper, mollis id, leo. Nulla ac massa eu risus blandit mattis. Mauris ut nunc. In hac habitasse platea dictumst. Aliquam eget tortor. Quisque dapibus pede in erat. Nunc enim. In dui nulla, commodo at, consectetur nec, malesuada nec, elit. Aliquam ornare tellus eu urna. Sed nec metus. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas.

Phasellus id magna. Duis malesuada interdum arcu. Integer metus. Morbi pulvinar pellentesque mi. Suspendisse sed est eu magna molestie egestas. Quisque mi lorem, pulvinar eget, egestas quis, luctus at, ante. Proin auctor vehicula purus. Fusce ac nisl aliquam ante hendrerit pellentesque. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Morbi wisi. Etiam arcu mauris, facilisis sed, eleifend non, nonummy ut, pede. Cras ut lacus tempor metus mollis placerat. Vivamus eu tortor vel metus interdum malesuada.

Sed eleifend, eros sit amet faucibus elementum, urna sapien consectetur mauris, quis egestas leo justo non risus. Morbi non felis ac libero vulputate fringilla. Mauris libero eros, lacinia non, sodales quis, dapibus porttitor, pede. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Morbi dapibus mauris condimentum nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Etiam sit amet erat. Nulla varius. Etiam tincidunt dui vitae turpis. Donec leo. Morbi vulputate convallis est. Integer aliquet. Pellentesque aliquet sodales urna.

Nullam eleifend justo in nisl. In hac habitasse platea dictumst. Morbi nonummy. Aliquam ut felis. In velit leo, dictum vitae, posuere id, vulputate nec, ante. Maecenas vitae pede nec dui dignissim suscipit. Morbi magna. Vestibulum id purus eget velit laoreet laoreet. Praesent sed leo vel nibh convallis blandit. Ut rutrum. Donec nibh. Donec interdum. Fusce sed pede sit amet elit rhoncus ultrices. Nullam at enim vitae pede vehicula iaculis.

Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Aenean nonummy turpis id odio. Integer euismod imperdiet turpis. Ut nec leo nec diam imperdiet lacinia. Etiam eget lacus eget mi ultricies posuere. In placerat tristique tortor. Sed porta vestibulum metus. Nulla iaculis sollicitudin pede. Fusce luctus tellus in dolor. Curabitur auctor velit a sem. Morbi sapien. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Donec adipiscing urna vehicula nunc. Sed ornare leo in leo. In rhoncus leo ut dui. Aenean dolor quam, volutpat

nec, fringilla id, consecetuer vel, pede.

Nulla malesuada risus ut urna. Aenean pretium velit sit amet metus. Duis iaculis. In hac habitasse platea dictumst. Nullam molestie turpis eget nisl. Duis a massa id pede dapibus ultricies. Sed eu leo. In at mauris sit amet tortor bibendum varius. Phasellus justo risus, posuere in, sagittis ac, varius vel, tortor. Quisque id enim. Phasellus consequat, libero pretium nonummy fringilla, tortor lacus vestibulum nunc, ut rhoncus ligula neque id justo. Nullam accumsan euismod nunc. Proin vitae ipsum ac metus dictum tempus. Nam ut wisi. Quisque tortor felis, interdum ac, sodales a, semper a, sem. Curabitur in velit sit amet dui tristique sodales. Vivamus mauris pede, lacinia eget, pellentesque quis, scelerisque eu, est. Aliquam risus. Quisque bibendum pede eu dolor.

Referências

- [1] A.S. Albahri, Yahya Layth Khaleel, Mustafa Abdulfattah Habeeb, Reem D. Ismael, Qabas A. Hameed, Muhammet Deveci, Raad Z. Homod, O.S. Albahri, A.H. Alamo-odi, and Laith Alzubaidi. A systematic review of trustworthy artificial intelligence applications in natural disasters. *Computers and Electrical Engineering*, 118:109409, September 2024. Citado na página 17.
- [2] Enner Alcântara, José Mantovani, Cheila Baião, Luana Pampuch, Marcelo Curtarelli, Yasmim Guimarães, Luciana R. Londe, João Vitor Ribeiro, Klécia Massi, Jose Marengo, Carlos Nobre, Arcilan Assireu, Cassiano Bortolozo, Silvio Jorge Coelho Simões, Javier Tomasella, Osvaldo Moraes, and Edward Park. Unprecedented flooding in porto alegre metropolitan region (southern brazil) in may 2024: Causes, risks, and impacts. *Unknown*, 2024. Citado na página 15.
- [3] Vida Atashi, Hamed Taheri Gorji, Seyed Mojtaba Shahabi, Ramtin Kardan, and Yeo Howe Lim. Water level forecasting using deep learning time-series analysis: A case study of red river of the north. *Water*, 14(12):1971, 2022. Citado na página 16.
- [4] Punyanuch Borwarnginn, Jason H. Haga, and Worapan Kusakunniran. Predicting river water height using deep learning-based features. *ICT Express*, 8(4):588–594, December 2022. Citado na página 17.
- [5] George E. P. Box, Gwilym M. Jenkins, Gregory C. Reinsel, and Greta M. Ljung. *Time Series Analysis: Forecasting and Control*. John Wiley & Sons, May 2015. Citado na página 16.
- [6] Cristian Challu, Kin G. Olivares, Boris N. Oreshkin, Federico Garza, Max Mergenthaler-Canseco, and Artur Dubrawski. N-hits: Neural hierarchical interpolation for time series forecasting, January 2022. Citado na página 17.
- [7] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, KDD '16, pages 785–794, New York, NY, USA, 2016. ACM. Citado na página 17.
- [8] Ta Quang Chieu, Nguyen Thi Phuong Thao, Dao Thi Hue, and Nguyen Thi Thu Huong. Prediction of the water level at the kien giang river based on regression techniques. *River*, 3(1):59–68, January 2024. Citado na página 16.
- [9] Jornal do Comércio. Nível do guaíba atinge recorde de 5,33 metros neste domingo. *Jornal do Comércio*, May 2024. Citado na página 15.

-
- [10] Departamento de Esgotos Pluviais. Departamento de esgotos pluviais. Accessed: 2024-10-19. Citado na página 15.
- [11] Instituto Brasileiro de Geografia e Estatística. Bacias e divisões hidrográficas do brasil 2021. Accessed: 2024-10-19. Citado na página 18.
- [12] Sistema Nacional de Informações sobre Recursos Hídricos. Portal do snirh. Accessed: 2024-10-19. Citado na página 18.
- [13] Instituto Nacional de Meteorologia. Banco de dados meteorológicos. Accessed: 2024-10-19. Citado na página 18.
- [14] Robert J. H. Dunn, Nicholas Herold, Lisa V. Alexander, Markus G. Donat, Rob Allan, Margot Bador, Manola Brunet, Vincent Cheng, Wan Maisarah Wan Ibadullah, Muhammad Khairul Izzat Bin Ibrahim, Andries Kruger, Hisayuki Kubota, Tanya J. R. Lippmann, Jose Marengo, Sifiso Mbatha, Simon McGree, Sandile Ngwenya, Jose Daniel Pabon Caicedo, Andrea Ramos, Jim Salinger, Gerard van der Schrier, Arvind Srivastava, Blair Trewin, Ricardo Vásquez Yáñez, Jorge Vazquez-Aguirre, Claudia Villaroel Jiménez, Russ Vose, Mohd Noor'Arifin Bin Hj Yussof, and Xuebin Zhang. Observed global changes in sector relevant climate extremes indices an extension to hadex3. *Earth and Space Science*, 11(4), April 2024. Citado na página 15.
- [15] Veysel Güldal and Hakan Tongal. Comparison of recurrent neural network, adaptive neuro-fuzzy inference system and stochastic models in eğirdir lake level forecasting. *Water Resources Management*, 24(1):105–128, May 2009. Citado na página 17.
- [16] M.J. Hammond, A.S. Chen, S. Djordjević, D. Butler, and O. Mark. Urban flood impact assessment: A state-of-the-art review. *Urban Water Journal*, 12(1):14–29, November 2013. Citado na página 15.
- [17] Rob J Hyndman and George Athanasopoulos. *Forecasting: Principles and Practice*. Otexts, May 2021. Citado na página 16.
- [18] IPH. Iph - notícias. Accessed: 2024-10-21. Citado na página 16.
- [19] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. Lightgbm: a highly efficient gradient boosting decision tree. In *Proceedings of the 31st International Conference on Neural Information Processing Systems*, NIPS'17, page 3149–3157, Red Hook, NY, USA, 2017. Curran Associates Inc. Citado na página 17.
- [20] Vaia I. Kontopoulou, Athanasios D. Panagopoulos, Ioannis Kakkos, and George K. Matsopoulos. A review of arima vs. machine learning approaches for time series

- forecasting in data driven networks. *Future Internet*, 15(8):255, July 2023. Citado na página 17.
- [21] Kaisheng Luo and Xuejun Zhang. Increasing urban flood risk in china over recent 40 years induced by lucc. *Landscape and Urban Planning*, 219:104317, March 2022. Citado na página 15.
- [22] Spyros Makridakis, Evangelos Spiliotis, Vassilios Assimakopoulos, Artemios-Anargyros Semenoglou, Gary Mulder, and Konstantinos Nikolopoulos. Statistical, machine learning and deep learning forecasting methods: Comparisons and ways forward. *Journal of the Operational Research Society*, 74(3):840–859, September 2022. Citado na página 16.
- [23] José Morales. Statistical vs deep learning forecasting methods, November 2022. Citado na página 16.
- [24] NASA. Ges disc, October 2024. Citado na página 18.
- [25] Y. Neria, A. Nandi, and S. Galea. Post-traumatic stress disorder following disasters: a systematic review. *Psychological Medicine*, 38(4):467–480, September 2007. Citado na página 15.
- [26] Rodrigo da Silva Pereira and André Becker Nunes. Estudo climático dos eventos de precipitação associados a alagamentos urbanos no estado do rio grande do sul (climatic study of rainfall events related to urban flash floods in rio grande do sul state). *Revista Brasileira de Geografia Física*, 11(6):2010–2017, January 2019. Citado na página 15.
- [27] Sara Reardon. Hurricane katrina’s psychological scars revealed. *Nature*, 524(7566):395–396, August 2015. Citado na página 15.
- [28] Long Yang, Yixin Yang, Ye Shen, Jiachuan Yang, Guang Zheng, James Smith, and Dev Niyogi. Urban development pattern’s influence on extreme rainfall occurrences. *Nature Communications*, 15(1), May 2024. Citado na página 15.

APÊNDICE A – Quisque libero justo

Quisque facilisis auctor sapien. Pellentesque gravida hendrerit lectus. Mauris rutrum sodales sapien. Fusce hendrerit sem vel lorem. Integer pellentesque massa vel augue. Integer elit tortor, feugiat quis, sagittis et, ornare non, lacus. Vestibulum posuere pellentesque eros. Quisque venenatis ipsum dictum nulla. Aliquam quis quam non metus eleifend interdum. Nam eget sapien ac mauris malesuada adipiscing. Etiam eleifend neque sed quam. Nulla facilisi. Proin a ligula. Sed id dui eu nibh egestas tincidunt. Suspendisse arcu.

ANEXO A – Morbi ultrices rutrum lorem.

Sed mattis, erat sit amet gravida malesuada, elit augue egestas diam, tempus scelerisque nunc nisl vitae libero. Sed consequat feugiat massa. Nunc porta, eros in eleifend varius, erat leo rutrum dui, non convallis lectus orci ut nibh. Sed lorem massa, nonummy quis, egestas id, condimentum at, nisl. Maecenas at nibh. Aliquam et augue at nunc pellentesque ullamcorper. Duis nisl nibh, laoreet suscipit, convallis ut, rutrum id, enim. Phasellus odio. Nulla nulla elit, molestie non, scelerisque at, vestibulum eu, nulla. Ut odio nisl, facilisis id, mollis et, scelerisque nec, enim. Aenean sem leo, pellentesque sit amet, scelerisque sit amet, vehicula pellentesque, sapien.