

Plano de pesquisa para o Trabalho de Conclusão de Curso

Análise comparativa de Modelos de Predição para Cheias no Rio Guaíba

Aluno: Juliano Almeida Machado
Orientador: Prof. Dr. Sebastián Gonçalves

1 Introdução

Desastres naturais provocados por eventos climáticos extremos causam impactos profundos e severos de diversas maneiras. No aspecto econômico, os recursos alocados para a recuperação de áreas afetadas enfraquecem a microeconomia local, tornando a região ainda mais vulnerável a eventos futuros. Estruturalmente, o tempo e o dinheiro investidos na construção e no aprimoramento de edificações, tanto privadas (como residências e negócios) quanto públicas (como infraestrutura urbana e áreas administrativas), podem ser comprometidos pela falta de preparação para lidar com tais ocorrências. Já o impacto social é, sem dúvida, o mais significativo. Este impacto, imensurável, é sentido por diversas gerações de pessoas afetadas por desastres, como evidenciado pelos efeitos do furacão Katrina [22] [18].

Devido às mudanças climáticas, a frequência e intensidade dos desastres naturais vêm aumentando gradualmente desde os anos 1950 [11]. Como resultado, muitas regiões estão sendo afetadas por eventos climáticos extremos de maneira cada vez mais rápida e despreparada. Entre esses desastres, as enchentes se destacam pela sua capacidade de causar destruição generalizada e afetar áreas densamente povoadas, especialmente em regiões urbanas com infraestrutura inadequada para gerenciar grandes volumes de água. No final de abril e início de maio de 2024, o estado do Rio Grande do Sul passou por um período de alta precipitação que resultou na cheia das suas principais bacias hidrográficas. Na Região Metropolitana de Porto Alegre, esse cenário culminou na maior cheia histórica do Rio Guaíba, que ultrapassou a marca de 4.76 metros, superando a cheia de 1941, até então considerada a mais devastadora

da cidade [3]. Esse desastre foi impulsionado por uma combinação de fatores meteorológicos, e, combinado com a maior vulnerabilidade de centros urbanos à enchentes [23] [12] [16] [21], levou à um evento de devastação generalizada, com milhares de pessoas deslocadas e centenas de vítimas fatais [5].

Durante a gestão da crise, o monitoramento e predição dos níveis de água do Rio Guaíba – o mais importante da região – foi fundamental para orientar os tomadores de decisão em suas ações de planejamento e para que a população pudesse reagir melhor à ameaça iminente. Essas previsões foram feitas principalmente através de modelos hidrológicos e hidrodinâmicos, que, embora precisos, são complexos, exigem grande quantidade de dados topográficos, meteorológicos e hidrológicos, requerem conhecimento especializado em hidrologia e demandam tempo de simulação prolongado. Esse último fator foi acentuado nos momentos mais delicados da crise, quando as previsões só podiam ser realizadas com uma frequência diária [14], o que as tornou insuficientes para atender às demandas de previsões em tempo real ou de curto prazo [6].

Uma alternativa que visa superar essas limitações são os modelos baseados em dados. Os mesmos utilizam técnicas como aprendizado de máquina para identificar e explorar relações estatísticas entre os dados de entrada e saída. Com a aprendizagem dos padrões presentes nos dados históricos, é possível mapear as dinâmicas subjacentes do sistema e utilizá-las para prever valores futuros. Assim, esses modelos são capazes de realizar previsões precisas com base em séries temporais, capturando tendências e comportamentos complexos que podem ser difíceis de modelar diretamente por meio de abordagens tradicionais. Modelos baseados em dados são mais rápidos e eficientes para previsões em tempo real, sendo uma escolha adequada para sistemas de alerta precoce e mitigação de desastres de cheias [10].

2 Objetivos

Este projeto tem como objetivo aplicar diferentes modelos de *Machine Learning* nas séries históricas do nível da água do Rio Guaíba, enriquecidas com dados externos relevantes do mesmo período, como o nível de rios afluentes, precipitação em áreas críticas, velocidade e direção dos ventos, temperatura, entre outros. A inclusão desses dados externos será avaliada para determinar sua relevância, visando otimizar o modelo ao utilizar o menor número possível de variáveis. Os modelos serão treinados com os mesmos dados e avaliados com diversas métricas de desempenho. Será então realizada

uma análise do comportamento e desempenho de cada modelo, buscando identificar padrões que possam contribuir para melhorar as previsões.

3 Metodologia

Neste trabalho, serão utilizados dados do Sistema Nacional de Informações sobre Recursos Hídricos (SNIRH), que disponibiliza informações das principais bacias hidrográficas do Brasil [4]. Esses dados serão a base para as séries históricas do nível de água, complementados por dados externos, como os do MERRA-2 (*Modern-Era Retrospective analysis for Research and Applications, Version 2*), um projeto da NASA que integra observações de satélites e estações terrestres para gerar dados meteorológicos globais [17]. Dados meteorológicos adicionais serão obtidos a partir de fontes públicas, como o Instituto Nacional de Meteorologia (INMET) e o Instituto Brasileiro de Geografia e Estatística (IBGE) [2] [1].

Esses dados serão processados em diferentes modelos de Redes Neurais Recorrentes, como *Long Short Term Memory* (LSTM) [13], além de modelos de Perceptron Multicamadas (MLP) especializados, como *Neural Hierarchical Interpolation for Time Series Forecasting* (NHITS) [7], *Neural Basis Expansion Analysis for Interpretable Time Series Forecasting* (NBEATS) [20] e *Time Series Mixer* (TSMixer) [8]. Todos esses modelos serão implementados em conjunto utilizando a biblioteca *NeuralForecast*, desenvolvida pela empresa Nixtla [19], que permite a execução paralela dos modelos sobre os mesmos dados. A validação cruzada por k-folds e as previsões dentro da amostra serão realizadas automaticamente pela estrutura da biblioteca.

A otimização dos hiperparâmetros será conduzida utilizando a ferramenta *Tune* da biblioteca Ray [15]. Além disso, modelos baseados em árvores de decisão, como *eXtreme Gradient Boosting* (XGBoost) [9], serão implementados paralelamente aos modelos mencionados. A comparação entre todos os modelos será feita com base em métricas de desempenho como o *Root Mean Squared Error* (RMSE), *Mean Absolute Error* (MAE) e o *Nash-Sutcliffe Model Efficiency Coefficient* (NSE).

4 Cronograma

	OUT/24	NOV/24	DEZ/24	JAN/25	FEV/25
Revisão Bibliográfica					
Modelagem matemática					
Análise dos resultados					
Elaboração do texto					
Ajustes					

Table 1: Tabela do cronograma

References

- [1] Bacias e divisões hidrográficas do brasil 2021. Accessed: 2024-10-19. 3
- [2] Banco de dados meteorológicos. Accessed: 2024-10-19. 3
- [3] Departamento de esgotos pluviais. Accessed: 2024-10-19. 2
- [4] Portal do snirh. Accessed: 2024-10-19. 3
- [5] Enner Alcântara, José Mantovani, Cheila Baião, Luana Pampuch, Marcelo Curtarelli, Yasmim Guimarães, Luciana R. Londe, João Vitor Ribeiro, Klécia Massi, Jose Marengo, Carlos Nobre, Arcilan Assireu, Cassiano Bortolozo, Silvio Jorge Coelho Simões, Javier Tomasella, Osvaldo Moraes, and Edward Park. *Unprecedented Flooding in Porto Alegre Metropolitan Region (Southern Brazil) in May 2024: Causes, Risks, and Impacts*. 2024. 2
- [6] Vida Atashi, Hamed Taheri Gorji, Seyed Mojtaba Shahabi, Ramtin Kardan, and Yeo Howe Lim. Water level forecasting using deep learning time-series analysis: A case study of red river of the north. *Water*, 14(12):1971, 2022. 2
- [7] Cristian Challu, Kin G. Olivares, Boris N. Oreshkin, Federico Garza, Max Mergenthaler-Canseco, and Artur Dubrawski. N-hits: Neural hierarchical interpolation for time series forecasting, January 2022. 3
- [8] Si-An Chen, Chun-ang Li Li, Nate Yoder, Sercan O. Arik, and Tomas Pfister. Tsmixer: An all-mlp architecture for time series forecasting, March 2023. 3

- [9] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, KDD '16, pages 785–794, New York, NY, USA, 2016. ACM. 3
- [10] Ta Quang Chieu, Nguyen Thi Phuong Thao, Dao Thi Hue, and Nguyen Thi Thu Huong. Prediction of the water level at the kien giang river based on regression techniques. *River*, 3(1):59–68, January 2024. 2
- [11] Robert J. H. Dunn, Nicholas Herold, Lisa V. Alexander, Markus G. Donat, Rob Allan, Margot Bador, Manola Brunet, Vincent Cheng, Wan Maisarah Wan Ibadullah, Muhammad Khairul Izzat Bin Ibrahim, Andries Kruger, Hisayuki Kubota, Tanya J. R. Lippmann, Jose Marengo, Sifiso Mbatha, Simon McGree, Sandile Ngwenya, Jose Daniel Pabon Caicedo, Andrea Ramos, Jim Salinger, Gerard van der Schrier, Arvind Srivastava, Blair Trewin, Ricardo Vásquez Yáñez, Jorge Vazquez-Aguirre, Claudia Villaroel Jiménez, Russ Vose, Mohd Noor'Arifin Bin Hj Yussof, and Xuebin Zhang. Observed global changes in sector-relevant climate extremes indices—an extension to hadex3. *Earth and Space Science*, 11(4), April 2024. 1
- [12] M.J. Hammond, A.S. Chen, S. Djordjević, D. Butler, and O. Mark. Urban flood impact assessment: A state-of-the-art review. *Urban Water Journal*, 12(1):14–29, November 2013. 2
- [13] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735–1780, November 1997. 3
- [14] IPH. Iph - notícias. Accessed: 2024-10-21. 2
- [15] Richard Liaw, Eric Liang, Robert Nishihara, Philipp Moritz, Joseph E Gonzalez, and Ion Stoica. Tune: A research platform for distributed model selection and training. *arXiv preprint arXiv:1807.05118*, 2018. 3
- [16] Kaisheng Luo and Xuejun Zhang. Increasing urban flood risk in china over recent 40 years induced by lucc. *Landscape and Urban Planning*, 219:104317, March 2022. 2
- [17] NASA. Ges disc, October 2024. 3
- [18] Y. Neria, A. Nandi, and S. Galea. Post-traumatic stress disorder following disasters: a systematic review. *Psychological Medicine*, 38(4):467–480, September 2007. 1

- [19] Kin G. Olivares, Cristian Challú, Federico Garza, Max Mergenthaler Canseco, and Artur Dubrawski. NeuralForecast: User friendly state-of-the-art neural forecasting models. PyCon Salt Lake City, Utah, US 2022, 2022. 3
- [20] Boris N. Oreshkin, Dmitri Carпов, Nicolas Chapados, and Yoshua Bengio. N-beats: Neural basis expansion analysis for interpretable time series forecasting, May 2019. 3
- [21] Rodrigo da Silva Pereira and André Becker Nunes. Estudo climático dos eventos de precipitação associados a alagamentos urbanos no estado do rio grande do sul (climatic study of rainfall events related to urban flash floods in rio grande do sul state). *Revista Brasileira de Geografia Física*, 11(6):2010–2017, January 2019. 2
- [22] Sara Reardon. Hurricane katrina’s psychological scars revealed. *Nature*, 524(7566):395–396, August 2015. 1
- [23] Long Yang, Yixin Yang, Ye Shen, Jiachuan Yang, Guang Zheng, James Smith, and Dev Niyogi. Urban development pattern’s influence on extreme rainfall occurrences. *Nature Communications*, 15(1), May 2024. 2